ΕΡΓΑΣΙΑ ΑΝΑΓΝΩΡΙΣΗ ΠΡΟΤΥΠΩΝ ΚΑΙ ΜΗΧΑΝΙΚΗ ΜΑΘΗΣΗ

Ακαδημαϊκό Έτος 2025-2026
ΟΜΑΔΑ 45

ΜΕΛΗ ΟΜΑΔΑΣ:
Ελένη Λαζαρίδου 10859
Αλέξανδρος Σουρουλλάς 10819

ΔΟΜΗ ΠΑΡΟΥΣΙΑΣΗΣ

ΜΕΡΟΣ Α : Μέγιστη Πιθανοφάνεια

- **Θεωρητικό Υπόβαθρο & Στόχος**
- **Υλοποίηση & Αλγόριθμος**
- **Αποτελέσματα & Οπτικοποιήσεις**

ΜΕΡΟΣ Β : Parzen Windows

- **Θεωρία Kernel Estimation**
- **Υλοποίηση 2 Kernels**
- **Βέλτιστο Bandwidth h**

ΜΕΡΟΣ Γ : KNN Classifier

- **Χειροκίνητη Υλοποίηση KNN**
- **Εύρεση Βέλτιστου k**
- **Decision Boundaries**

ΜΕΡΟΣ Δ : Custom Classifier

- **Ανάλυση & Προεπεξεργασία**
- **Model Selection & Training**
- **Αποτελέσματα & Συμπεράσματα**

ΜΕΡΟΣ Α - ΜΕΓΙΣΤΗ ΠΙΘΑΝΟΦΑΝΕΙΑ

ΣΤΟΧΟΣ ΜΕΡΟΥΣ Α

ΔΕΔΟΜΕΝΑ: dataset1.csv

- 300 δείγματα 2 διαστάσεων
- 3 κλάσεις (100 δείγματα/κλάση)
- Κάθε κλάση από διαφορετική κανονική κατανομή

ΣΤΟΧΟΣ:

- Χρήση Μέγιστης Πιθανοφάνειας (MLE)
- Εκτίμηση παραμέτρων (μ, Σ) για τις 3 κατανομές
- Χειροκίνητη υλοποίηση (χωρίς βιβλιοθήκες)
- Ενιαίο 3D plot και των 3 κατανομών

ΘΕΩΡΗΤΙΚΟ ΥΠΟΒΑΘΡΟ - MLE

ΓΙΑ ΚΑΝΟΝΙΚΗ ΚΑΤΑΝΟΜΗ N(μ, Σ):

ΠΥΚΝΟΤΗΤΑ ΠΙΘΑΝΟΤΗΤΑΣ (2D):

$$f(\mathbf{x}) = \frac{1}{2\pi|\Sigma|^{1/2}} \exp\left(-\frac{1}{2}(\mathbf{x}-\mu)^T\Sigma^{-1}(\mathbf{x}-\mu)\right)$$

ΕΚΤΙΜΗΤΕΣ MLE:

- **ΜΕΣΟΣ:** $\hat{\mu} = \frac{1}{n}\sum_{i=1}^{n} x_i$
- **ΣΥΝΔΙΑΣΠΟΡΑ:** $\hat{\Sigma} = \frac{1}{n}\sum_{i=1}^{n}(x_i - \hat{\mu})(x_i - \hat{\mu})^T$

ΥΠΟΛΟΓΙΣΜΟΙ: Χειροκίνητα χωρίς np.mean() ή np.cov()

ΑΠΟΤΕΛΕΣΜΑΤΑ - ΕΚΤΙΜΗΜΕΝΕΣ ΠΑΡΑΜΕΤΡΟΙ

ΚΛΑΣΗ 0:

- **Μέσος: μ_0 = [29.20903802 16.84988855]**
- **Συνδιασπορά:[[46.98591258 22.90532295]**

  [22.90532295 48.63133559]]

ΚΛΑΣΗ 1:

- **Μέσος: μ_1 = [40.19766916 34.28109099]**
- **Συνδιασπορά: Σ_1 =[[9.42390491 11.48971771]**

  [11.48971771 20.10805596]]

ΚΛΑΣΗ 2:

- **Μέσος: μ_2 = [27.55232503 34.79318037]**
- **Συνδιασπορά: Σ_2 = [[13.96874391 11.77433636]**

  [11.77433636 25.28848192]]

ΟΠΤΙΚΟΠΟΙΗΣΗ - 3D PLOT

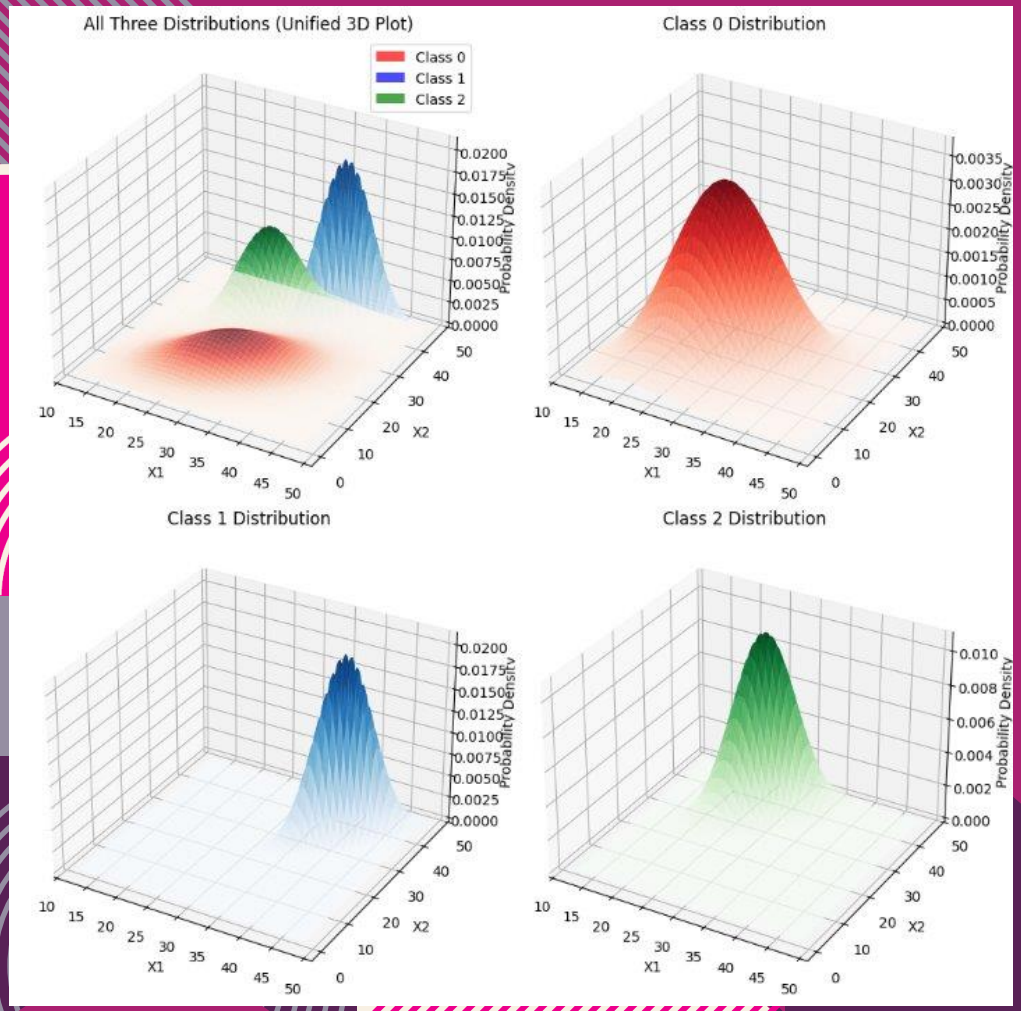

ΕΝΙΑΙΟ 3D PLOT ΚΑΙ ΤΩΝ 3 ΚΑΤΑΝΟΜΩΝ:

- **Αξονας X: Feature 1**
- **Αξονας Y: Feature 2**
- **Αξονας Z: Πυκνότητα Πιθανότητας**

ΧΡΩΜΑΤΙΚΟΣ ΚΩΔΙΚΑΣ:

- **Κλάση 0: Κόκκινο (Reds colormap)**
- **Κλάση 1: Μπλε (Blues colormap)**
- **Κλάση 2: Πράσινο (Greens colormap)**

ΣΥΜΠΕΡΑΣΜΑΤΑ ΜΕΡΟΥΣ Α

ΕΠΙΤΕΥΓΜΑΤΑ:

- ΕΠΙΤΥΧΉΣ ΕΚΤΊΜΗΣΗ ΠΑΡΑΜΈΤΡΩΝ ΜΕ MLE
- ΣΩΣΤΌΣ ΥΠΟΛΟΓΙΣΜΌΣ ΜΈΣΟΥ ΚΑΙ ΣΥΝΔΙΑΣΠΟΡΆΣ
- ΕΝΙΑΊΑ 3D ΟΠΤΙΚΟΠΟΊΗΣΗ

ΒΑΣΙΚΕΣ ΠΑΡΑΤΗΡΗΣΕΙΣ:

- ΟΙ ΕΚΤΙΜΗΤΈΣ MLE ΕΊΝΑΙ ΑΜΕΡΌΛΗΠΤΟΙ
- ΚΆΘΕ ΚΛΆΣΗ 'ΈΧΕΙ ΔΙΑΚΡΙΤΌ ΚΈΝΤΡΟ ΚΑΤΑΝΟΜΉΣ
- ΟΙ ΠΊΝΑΚΕΣ ΣΥΝΔΙΑΣΠΟΡΆΣ ΔΕΊΧΝΟΥΝ ΔΙΑΦΟΡΕΤΙΚΌ ΣΧΉΜΑ ΓΙΑ ΚΆΘΕ ΚΛΆΣΗ

ΜΕΡΟΣ Β - PARZEN WINDOWS

ΣΤΟΧΟΣ ΜΕΡΟΥΣ Β

ΔΕΔΟΜΕΝΑ: DATASET2.CSV
- 200 ΜΟΝΟΔΙΆΣΤΑΤΑ ΔΕΊΓΜΑΤΑ
- ΠΡΟΈΡΧΟΝΤΑΙ ΑΠΌ N(1,4)

ΣΤΟΧΟΣ:
- ΥΛΟΠΟΊΗΣΗ ΜΕΘΌΔΟΥ PARZEN WINDOWS
- 2 KERNELS: ΥΠΕΡΚΎΒΟΣ ΚΑΙ GAUSSIAN
- ΕΎΡΕΣΗ ΒΈΛΤΙΣΤΟΥ BANDWIDTH H
- ΣΎΓΚΡΙΣΗ ΜΕ TRUE DISTRIBUTION N(1,4)

ΘΕΩΡΙΑ PARZEN WINDOWS

ΤΥΠΟΣ ΕΚΤΙΜΗΣΗΣ ΠΥΚΝΟΤΗΤΑΣ:

$$\hat{p}(x) = \frac{1}{Nh} \sum_{i=1}^{N} K\left(\frac{x - x_i}{h}\right)$$

Όπου:

- N: αριθμός δειγμάτων
- h: bandwidth (παράμετρος εξομάλυνσης)
- K: kernel function
- x_i: δείγματα εκπαίδευσης

<u>Βασική Ιδέα:</u>

- Εκτίμηση πυκνότητας βασισμένη σε τοπικά δεδομένα
- Το h ελέγχει την εξομάλυνση (μικρό h: λεπτομέρεια, μεγάλο h: ομαλότητα)

KERNEL ΣΥΝΑΡΤΗΣΕΙΣ:

1. **ΥΠΕΡΚΥΒΟΣ:** $K(u) = 1$ αν $|u| \leq 0.5$, αλλιώς 0
2. **GAUSSIAN:** $K(u) = \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}u^2}$

1. Hypercube (Uniform) Kernel:

- Απλό, διακριτό
- Ίδιο βάρος σε όλα τα σημεία εντός του παραθύρου.

2. Gaussian Kernel:

- Ομαλό, συνεχές
- Μεγαλύτερο βάρος σε πλησιέστερα σημεία

ΕΠΙΒΕΒΑΙΩΣΗ ΚΑΤΑΝΟΜΗΣ

Στατιστικά Δεδομένων:

- Μέσος όρος: ~1.0
- Τυπική απόκλιση: ~2.0
- Εύρος: [-5.6, 5.9]

Shapiro-Wilk Test:

- Έλεγχος κανονικότητας
- p-value > 0.05 → Τα δεδομένα φαίνονται κανονικά

Ιστόγραμμα:

- 30 bins για οπτικοποίηση
- Επικάλυψη με θεωρητική N(1,4) καμπύλη (κόκκινη γραμμή)
- Εξαιρετική ταύτιση με θεωρητική κατανομή

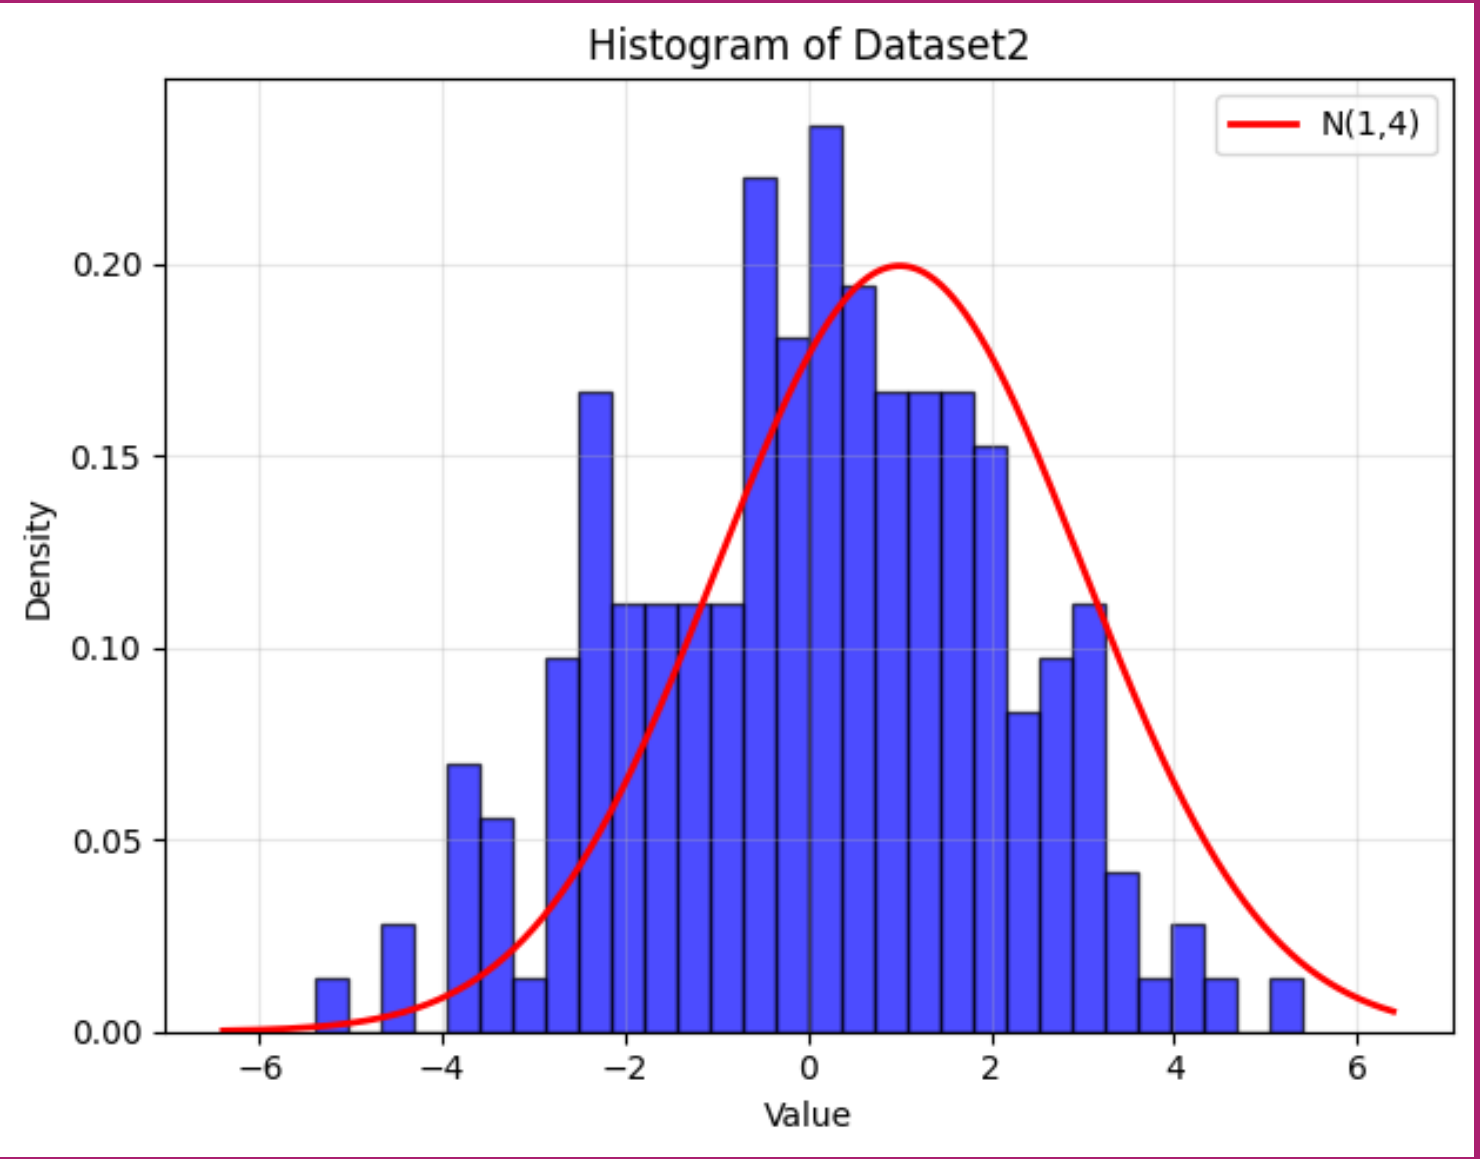
Histogram of Dataset2
N(1,4)
Density
0.20
0.15
0.10
0.05
0.00
−6
−4
−2
0
2
4
6
Value

ΑΠΟΤΕΛΕΣΜΑΤΑ

Hypercube kernel:

Βέλτιστο h = 3.00 Ελάχιστο MSE = 0.001081

Gaussian kernel:

Βέλτιστο h = 0.90 Ελάχιστο MSE = 0.001075

Γιατί διαφορετικό βέλτιστο h;

Hypercube (h=3.00):

- Σκληρά όρια (cut-off)
- Χρειάζεται μεγαλύτερο παράθυρο για ομαλότητα
- Απότομες μεταβάσεις

Gaussian (h=0.90):

- Ομαλή εξασθένηση βαρών
- Μικρότερο h επαρκεί για καλή κάλυψη
- Φυσική εξομάλυνση από τον πυρήνα

ΣΥΜΠΕΡΑΣΜΑΤΑ ΜΕΡΟΥΣ Β

ΒΑΣΙΚΑ ΕΥΡΗΜΑΤΑ:

1. Parzen Windows είναι non-parametric μέθοδος
2. Gaussian kernel καλύτερη απόδοση για smooth distributions
3. Bandwidth h ελέγχει bias-variance tradeoff

Παραμετρος h:
Ελέγχει βαθμό εξομάλυνσης
Μικρο h -> Υψηλή διακύμανση
Μεγάλο h -> Υψηλό bias

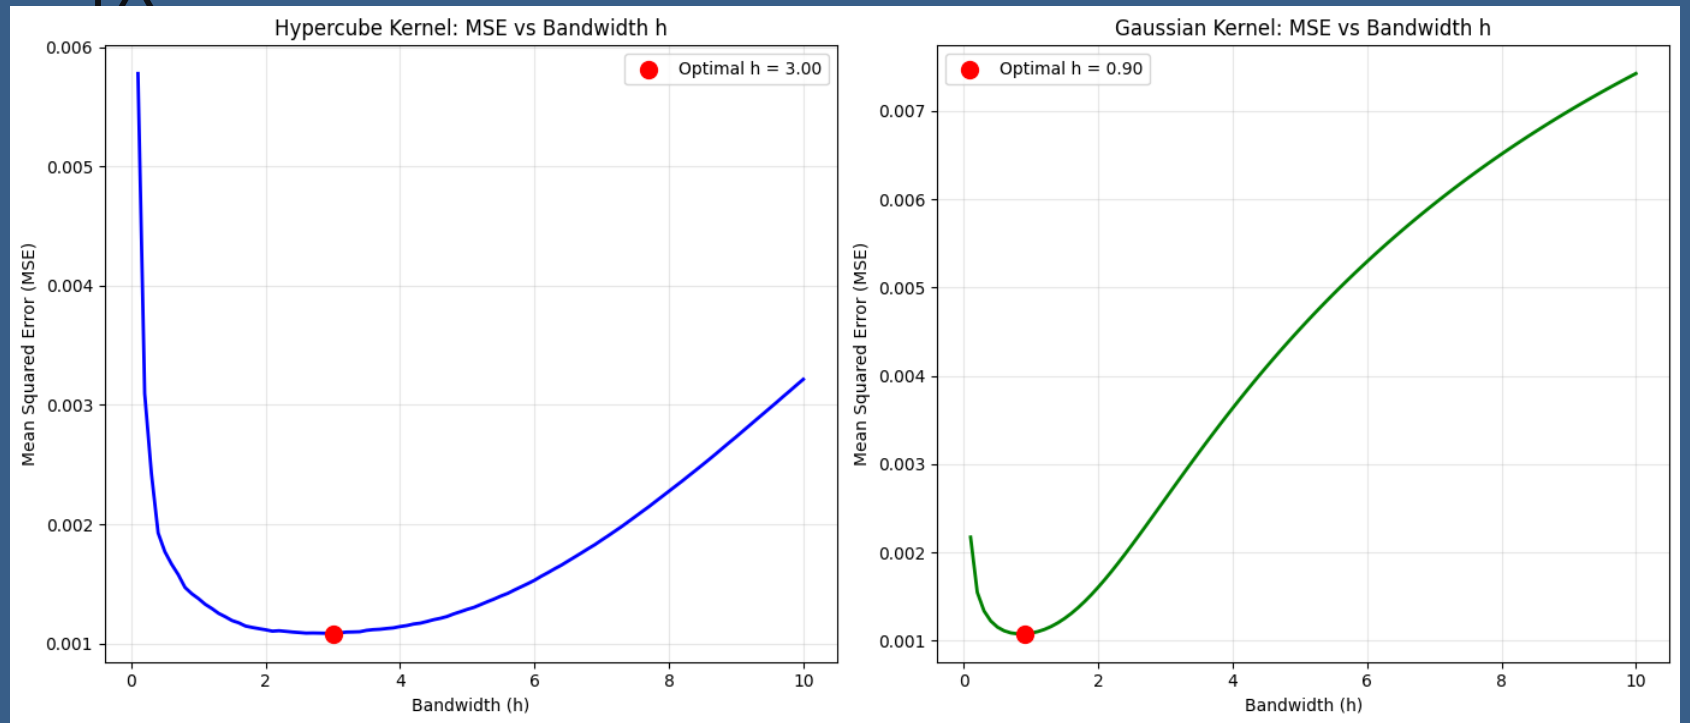

ΜΕΡΟΣ Γ - KNN CLASSIFIER

ΣΤΟΧΟΣ ΜΕΡΟΥΣ Γ

ΔΕΔΟΜΕΝΑ:

- Εκπαίδευση: dataset3.csv (50 δείγματα, 2 features)
- Δοκιμή: testset.csv (50 δείγματα)

ΣΤΟΧΟΣ:

- Χειροκίνητη υλοποίηση KNN
- 3 συναρτήσεις: eucl(), neighbors(), predict()
- Εύρεση βέλτιστου k
- Decision boundaries visualization

ΥΛΟΠΟΙΗΣΗ - ΣΥΝΑΡΤΗΣΗ ΕΥΚΛΕΙΔΕΙΑΣ ΑΠΟΣΤΑΣΗΣ

Συνάρτηση: eucl(x, trainData)

Μαθηματικός Τύπος: $d(x, y) = \sqrt{[(x_1 - y_1)^2 + (x_2 - y_2)^2]}$

- Επιτρέπονται μόνο βασικές πράξεις πινάκων (np.sqrt, np.sum).
- Υπολογίζει απόσταση από ένα σημείο σε όλα τα δεδομένα εκπαίδευσης.
- **Έξοδος:** Οι αποστάσεις του ενός σημείου από όλα τα δεδομένα εκπαίδευσης.

ΥΛΟΠΟΙΗΣΗ - ΣΥΝΑΡΤΗΣΗ ΕΥΡΕΣΗΣ ΓΕΙΤΟΝΩΝ

Συνάρτηση: neighbors(x, trainData, k)

Λειτουργία:

- Υπολογισμός αποστάσεων από x σε όλα τα training δεδομένα.
- Ταξινόμηση αποστάσεων.
- Επιστροφή k πλησιέστερων γειτόνων.
- **Έξοδος:** Τα k πλησιέστερα σημεία

ΥΛΟΠΟΙΗΣΗ - ΣΥΝΑΡΤΗΣΗ ΠΡΟΒΛΕΨΗΣ

Συνάρτηση: predict(testData, trainData, k)

Διαδικασία:

- Για κάθε test σημείο, βρίσκει k πλησιέστερους γείτονες
- Μετράει κλάσεις των γειτόνων (count_0, count_1)
- Υπολογίζει πιθανότητες: P(class=0) και P(class=1)

Υπολογισμός Πιθανοτήτων:

- P(class=0) = count_0 / k
- P(class=1) = count_1 / k
- P(class=0) + P(class=1) = 1.0 (πάντα)

Έξοδος: Δύο πιθανότητες για κάθε test σημείο

ΕΥΡΕΣΗ ΒΕΛΤΙΣΤΟΥ Κ

ΜΕΘΟΔΟΣ:

- k από 1 έως 30

Για κάθε k:

- Predict στο test set
- Υπολογισμός accuracy
- Επιλογή k με μέγιστη accuracy

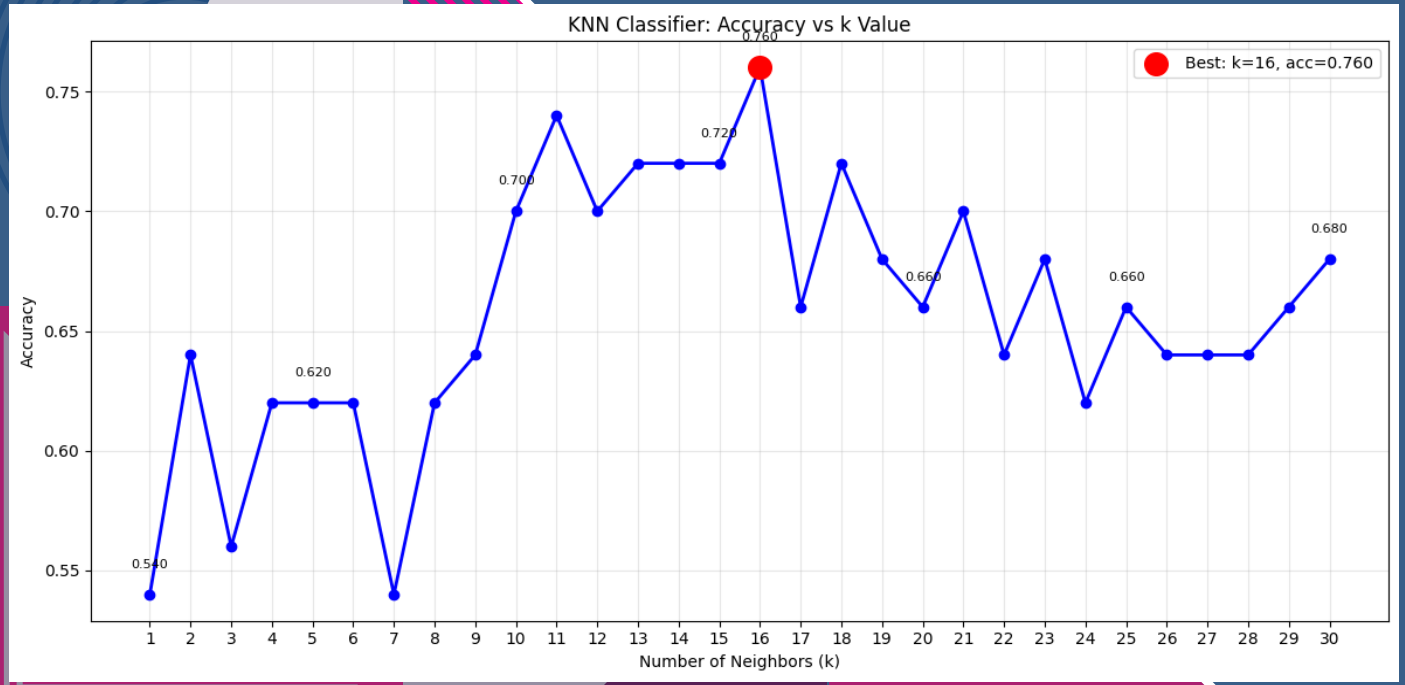

ΑΠΟΤΕΛΕΣΜΑΤΑ - ΒΕΛΤΙΣΤΟ k

ΒΕΛΤΙΣΤΟ k: 16

ΜΕΓΙΣΤΗ ACCURACY: 0.76 (76.0%)

ACCURACY vs k PLOT:

- Καμπύλη για k=1 έως 30
- Τοπικά μέγιστα/ελάχιστα
- Σημείο βέλτιστου k επισημασμένο

ΠΑΡΑΤΗΡΗΣΕΙΣ:

- Μικρό k: High variance, ευαίσθητο στο noise
- Μεγάλο k: Πιο σταθερό αλλά μπορεί να underfit
- Βέλτιστο k: Ισορροπία bias-variance

ΟΠΤΙΚΟΠΟΙΗΣΗ - DECISION BOUNDARIES

ΜΕΘΟΔΟΣ:

- ΔΗΜΙΟΥΡΓΊΑ MESH GRID
- ΠΡΌΒΛΕΨΗ ΚΛΑΣΗΣ ΓΙΑ ΚΆΘΕ ΣΗΜΕΊΟ ΤΟΥ GRID ΜΕ K=16
- ΧΡΉΣΗ CONTOURF ΓΙΑ ΠΕΡΙΟΧΈΣ ΑΠΌΦΑΣΗΣ

ΑΠΟΤΕΛΕΣΜΑΤΑ

CONFUSION MATRIX (ΜΕ ΒΕΛΤΙΣΤΟ K):

ΜΕΤΡΙΚΕΣ ΑΠΟΔΟΣΗΣ:

- ACCURACY: 0.7600
- PRECISION: 0.7353
- RECALL: 0.8929
- F1-SCORE: 0.8065

ΠΑΡΑΔΕΙΓΜΑΤΑ ΠΡΟΒΛΕΨΕΩΝ: 10 ΠΡΏΤΑ TEST POINTS

EXAMPLE PREDICTIONS (FIRST 10 TEST POINTS):

INDEX	FEATURES	TRUE	PRED	P(0)	P(1)	CORRECT
0	[5.59, 35.70]	1	1	0.500	0.500	YES
1	[13.33, 40.29]	0	0	0.750	0.250	YES
2	[10.73, 28.26]	1	1	0.250	0.750	YES
3	[6.25, 25.74]	1	1	0.188	0.812	YES
4	[12.31, 29.04]	1	1	0.375	0.625	YES
5	[16.28, 31.79]	1	0	0.562	0.438	NO
6	[24.10, 34.99]	1	1	0.500	0.500	YES
7	[20.38, 30.29]	0	1	0.500	0.500	NO
8	[14.72, 28.86]	1	1	0.500	0.500	YES
9	[10.37, 22.88]	0	1	0.250	0.750	NO

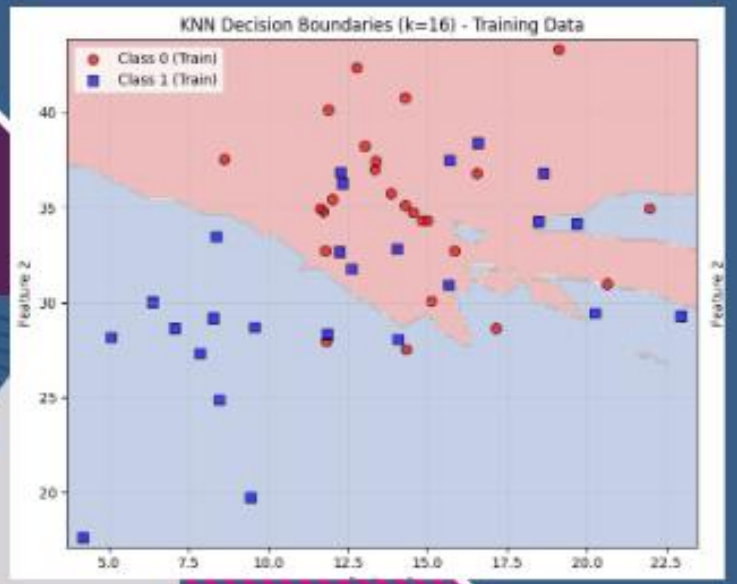

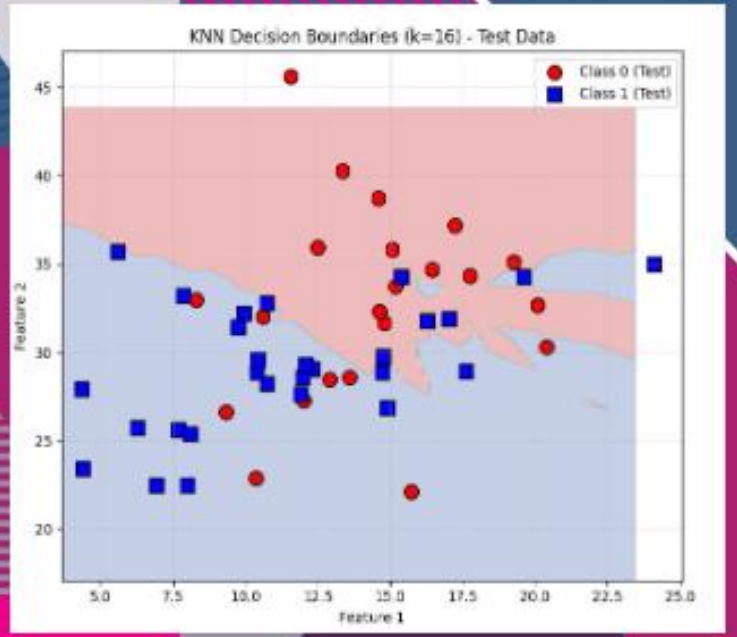

ΑΝΑΛΥΣΗ ΟΡΙΩΝ ΑΠΟΦΑΣΗΣ - TRAINING DATA

Χαρακτηριστικά:

- Μη γραμμικά όρια απόφασης.
- Ομαλές μεταβάσεις μεταξύ κλάσεων.
- Καλός διαχωρισμός στις περισσότερες περιοχές.

Παρατηρήσεις:

- Training δεδομένα καλά διαχωρισμένα
- Κάποια επικάλυψη στην κεντρική περιοχή
- k=16 παρέχει καλή εξομάλυνση

ΑΝΑΛΥΣΗ ΟΡΙΩΝ ΑΠΟΦΑΣΗΣ - TEST DATA

Απόδοση στα Test Δεδομένα:

- 76% ακρίβεια (38/50 σωστές προβλέψεις)
- 12 εσφαλμένες ταξινομήσεις

Παρατηρήσεις:

- Τα περισσότερα test σημεία πέφτουν σωστά στις περιοχές τους
- Λάθη κυρίως στα σύνορα των κλάσεων
- Καλή γενίκευση από training σε test

ΣΥΜΠΕΡΑΣΜΑΤΑ

Επιτεύγματα:

- Βέλτιστο k=16 με 76% ακρίβεια
- Οπτικοποίηση μη γραμμικών ορίων απόφασης

Βασικά Σημεία:

- Χαμηλό k: Υψηλή διακύμανση (overfitting)
- Βέλτιστο k: Ισορροπία bias-variance
- Υψηλό k: Υψηλό bias (underfitting)

CUSTOM CLASSIFIER

ΣΤΟΧΟΣ ΜΕΡΟΥΣ Δ

ΔΕΔΟΜΕΝΑ:

- ΕΚΠΑΊΔΕΥΣΗ: DATASETTV.CSV (8743 SAMPLES, 224 FEATURES)
- ΔΟΚΙΜΉ: DATASETTEST.CSV (6955 SAMPLES)
- 5 ΚΛΆΣΕΙΣ (LABELS 1-5)

ΣΤΟΧΟΣ:

- ΑΝΆΠΤΥΞΗ CUSTOM CLASSIFIER
- ΠΡΟΕΠΕΞΕΡΓΑΣΊΑ & FEATURE ENGINEERING
- MODEL SELECTION & TRAINING
- PREDICTIONS ΣΤΟ TEST SET

DATASET ANALYSIS

DATASETTV.CSV (TRAINING):

- ΔΕΊΓΜΑΤΑ: 8743
- FEATURES: 224
- ΚΛΆΣΕΙΣ: 5 (1, 2, 3, 4, 5)

DATASETTEST.CSV (TEST):

- ΔΕΊΓΜΑΤΑ: 6955
- FEATURES: 224
- LABELS: ΔΕΝ ΔΊΝΟΝΤΑΙ

INITIAL STATISTICS:

- MISSING VALUES: 0

- ΟΙ ΤΙΜΈΣ ΤΩΝ ΜΠΑΡΏΝ ΕΊΝΑΙ ΠΟΛΎ ΚΟΝΤΆ (1769, 1720, 1754, 1716, 1784).
- **Η ΚΑΤΑΝΟΜΉ ΕΊΝΑΙ ΣΧΕΔΌΝ ΙΣΟΡΡΟΠΗΜΈΝΗ**, ΧΩΡΊΣ ΜΕΓΆΛΗ ΔΙΑΦΟΡΆ ΜΕΤΑΞΎ ΤΩΝ ΚΛΆΣΕΩΝ.
- ΑΥΤΌ ΕΊΝΑΙ **ΚΑΛΌ ΓΙΑ ΤΗΝ ΕΚΠΑΊΔΕΥΣΗ ΕΝΌΣ ΜΟΝΤΈΛΟΥ**, ΚΑΘΏΣ ΔΕΝ ΥΠΆΡΧΕΙ ΣΗΜΑΝΤΙΚΉ ΑΝΙΣΟΡΡΟΠΊΑ ΚΛΆΣΕΩΝ (CLASS IMBALANCE). TRAINING SET BALANCE:
- CLASS 1: 1,769 SAMPLES (20.2%)
- CLASS 2: 1,720 SAMPLES (19.7%)
- CLASS 3: 1,754 SAMPLES (20.1%)
- CLASS 4: 1,716 SAMPLES (19.6%)
- CLASS 5: 1,784 SAMPLES (20.4%)

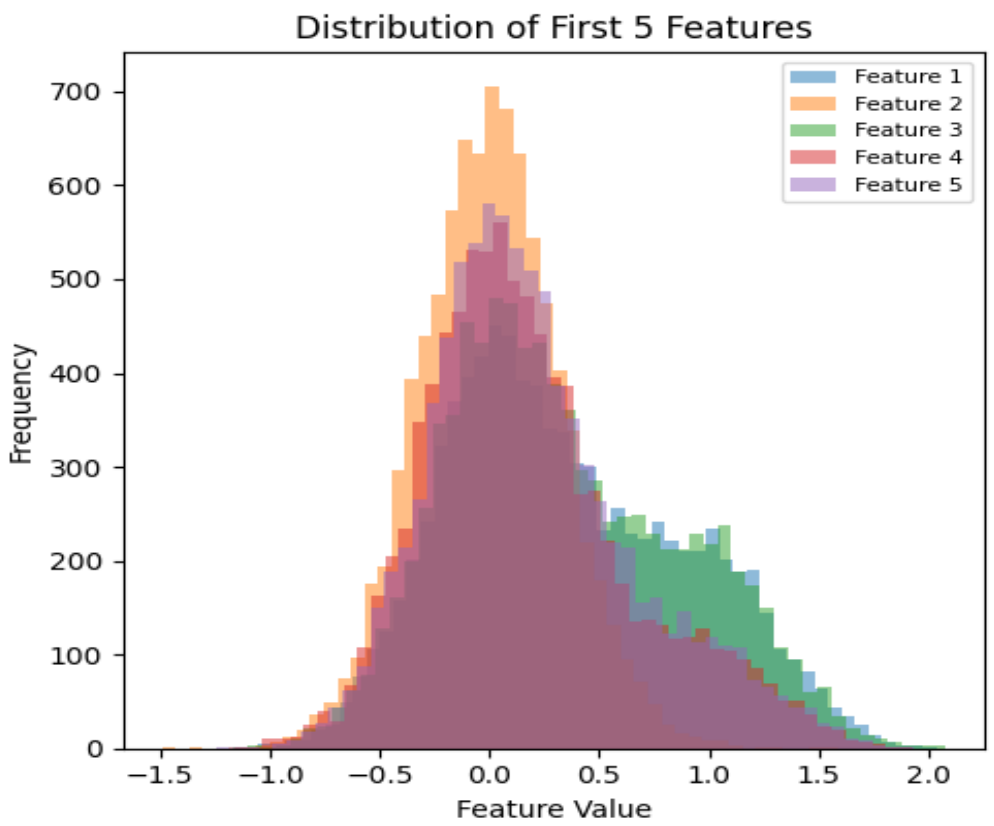

ΑΝΑΛΥΣΗ ΧΑΡΑΚΤΗΡΙΣΤΙΚΩΝ

Αρχικά Στατιστικά:

- Εύρος χαρακτηριστικών: [-1.63, 2.87]
- Μέσος όρος: 0.25, Τυπική απόκλιση: 0.52
- Μέση συσχέτιση: 0.097 (χαμηλή πολυσυγραμμικότητα)

Παρατηρήσεις:

- 224 χαρακτηριστικά = Χώρος υψηλής διάστασης
- Τα χαρακτηριστικά εμφανίζουν κανονικές κατανομές
- Η χαμηλή συσχέτιση υποδηλώνει ανεξάρτητα χαρακτηριστικά

Συνεπαγωγή: Η μείωση διαστασιμότητας είναι επωφελής για την αποδοτικότητα

ΔΙΑΔΙΚΑΣΊΑ ΠΡΟΕΠΕΞΕΡΓΑΣΊΑΣ

Ροή Διαδικασίας:

Ακατέργαστα Δεδομένα → Τυποποίηση → PCA → Εκπαίδευση Μοντέλου

Βασικά Βήματα:

- StandardScaler: Μηδενικός μέσος, μοναδιαία διακύμανση
- PCA (95%): 224 → 190 συνιστώσες
- Κωδικοποίηση ετικετών: [1-5] → [0-4] για sklearn

Αποτέλεσμα: 15% μείωση χαρακτηριστικών, 95% διατήρηση διακύμανσης

ΜΕΊΩΣΗ ΔΙΑΣΤΑΣΙΜΌΤΗΤΑΣ ΜΕ PCA

Μετασχηματισμός:

- Αρχικά: 224 χαρακτηριστικά
- Μετά το PCA: 190 συνιστώσες
- Διακύμανση που εξηγείται: 95.00%

Οφέλη:

- Μειωμένη υπολογιστική πολυπλοκότητα
- Αφαίρεση θορύβου και πλεονασμού
- Βελτιωμένη ταχύτητα εκπαίδευσης
- Διατήρηση διακριτικής ισχύος

ΑΡΧΙΚΟ ΜΟΝΤΈΛΟ - ΒΑΣΙΚΗ ΓΡΑΜΜΗ RANDOM FOREST

Γιατί Random Forest Πρώτα;

- Καλό σημείο εκκίνησης για προβλήματα πολλαπλών κλάσεων
- Χειρίζεται καλά δεδομένα υψηλής διάστασης
- Ελάχιστη ρύθμιση υπερπαραμέτρων
- Παρέχει σημαντικότητα χαρακτηριστικών

Αρχική Διαμόρφωση:

- n_estimators: 100
- max_depth: None (πλήρως ανεπτυγμένα δέντρα)
- Προεπιλεγμένες παράμετροι sklearn

Αρχικά Αποτελέσματα (5-Fold CV):

- Μέση ακρίβεια: 77.98% (± 2.90%)
- Δημιουργεί βασική απόδοση

ΡΎΘΜΙΣΗ ΥΠΕΡΠΑΡΑΜΈΤΡΩΝ (RANDOM FOREST)

Διαμόρφωση Grid Search:

- n_estimators: [50, 100, 200]
- max_depth: [None, 10, 20]
- min_samples_split: [2, 5]
- min_samples_leaf: [1, 2, 4]

Αποτελέσματα Grid Search:

- 3-fold CV για ταχύτερο υπολογισμό
- 36 συνδυασμοί παραμέτρων δοκιμάστηκαν
- Οριακή βελτίωση έναντι της βασικής γραμμής

Παρατήρηση: Η περιορισμένη βελτίωση πρότεινε τη δοκιμή άλλων αλγορίθμων

ΕΠΙΛΟΓΉ ΜΟΝΤΈΛΟΥ - ΣΎΓΚΡΙΣΗ ΑΛΓΟΡΊΘΜΩΝ

5 Μοντέλα Δοκιμάστηκαν (3-Fold CV):

Μοντέλο	Ακρίβεια CV
Random Forest	77.67%
SVM (RBF)	84.22%
Logistic Regression	76.59%
KNN	80.36%
XGBoost	81.94%

Νικητής: SVM με ακρίβεια 84.22%

ΣΤΡΑΤΗΓΙΚΉ ΕΚΠΑΊΔΕΥΣΗΣ ΚΑΙ ΕΠΙΚΎΡΩΣΗΣ

Χειρισμός Ετικετών:

- Αρχικές [1,2,3,4,5] → [0,1,2,3,4] για sklearn
- Μετατροπή πίσω σε [1-5] για τελική έξοδο

Προσέγγιση Επικύρωσης:

- Διασταυρούμενη επικύρωση: 3-fold stratified (επιλογή μοντέλου)
- Hold-out: 80-20 διαχωρισμός (τελική αξιολόγηση)
- Τελικό μοντέλο: Εκπαιδευμένο σε όλα τα 8.743 δείγματα

ΑΠΟΤΕΛΕΣΜΑΤΑ ΕΠΙΚΥΡΩΣΗΣ

Σύνολο Hold-out (1.749 δείγματα):

Μετρική	Βαθμολογία
Ακρίβεια	86.16%
Ακρίβεια (Precision)	86.25%
Ανάκληση (Recall)	86.16%
F1-Score	86.09%

- Ισχυρή ισορροπημένη απόδοση
- **Βελτίωση 2% έναντι CV** υποδηλώνει καλή γενίκευση

ΠΙΝΑΚΑΣ ΣΎΓΧΥΣΗΣ - ΑΠΟΔΟΣΗ ΑΝΑΚΛΑΣΗ

<u>Ακρίβεια ανά Κλάση:</u>

- Κλάση 0: 97.7% (346/354) - Εξαιρετική
- Κλάση 1: 67.7% (233/344) - Προκλητική
- Κλάση 2: 91.4% (329/360) - Πολύ καλή
- Κλάση 3: 90.7% (311/343) - Πολύ καλή
- Κλάση 4: 80.9% (288/357) - Καλή

Βασική Παρατήρηση: Η Κλάση 1 είναι η πιο δύσκολη για ταξινόμηση

Κύρια σφάλματα:

- Κλάση 1 → 4: 93 σφάλματα (27% της Κλάσης 1)
- Κλάση 4 → 1: 54 σφάλματα (15% της Κλάσης 4)

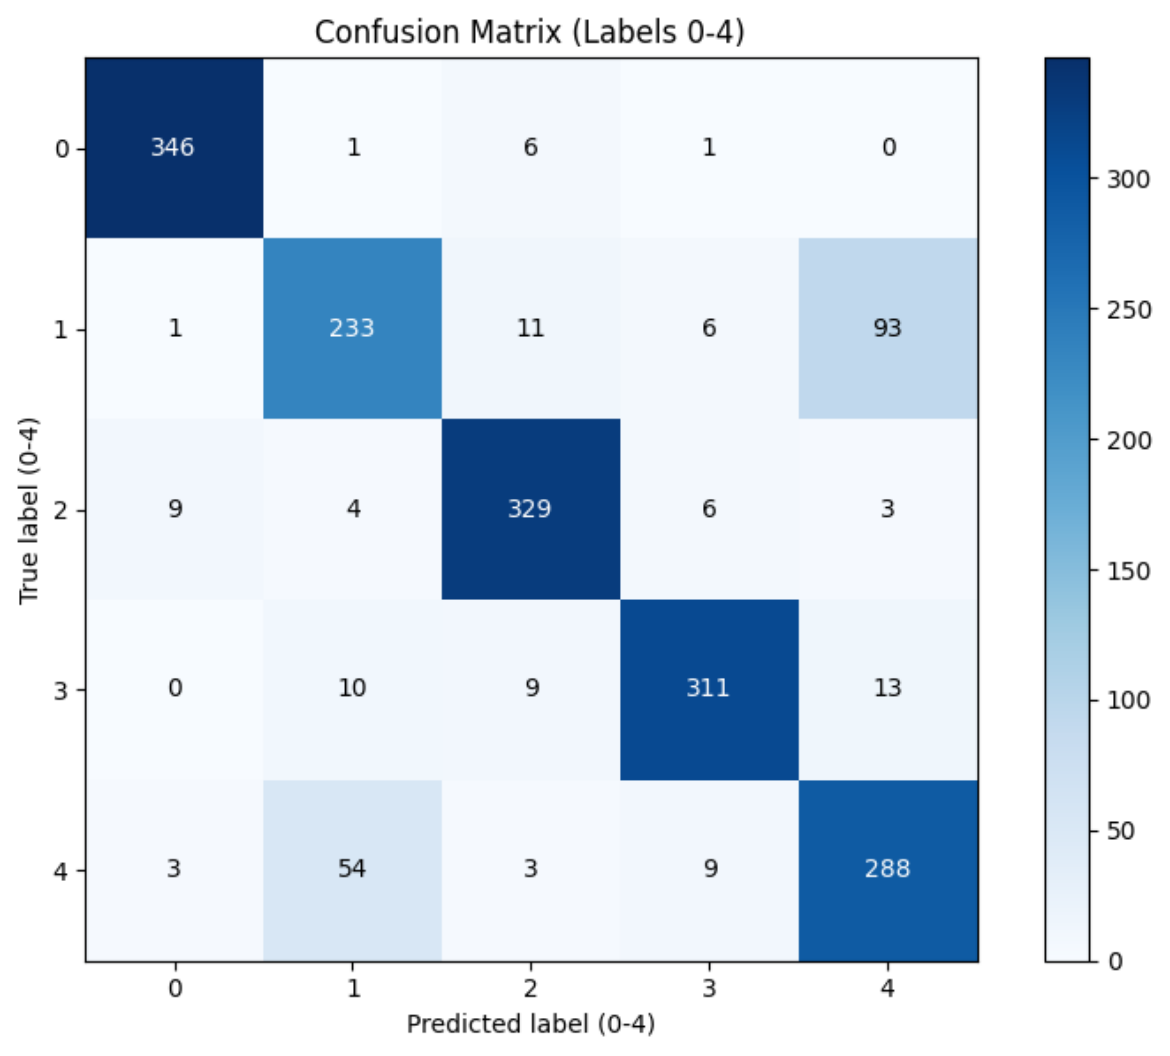

ΑΝΑΛΥΣΗ ΣΦΑΛΜΑΤΩΝ - ΣΥΓΧΥΣΗ ΚΛΑΣΗΣ 1 VS 4

Γιατί αυτή η σύγχυση;

- Μεγαλύτερο σφάλμα: 93 εσφαλμένες ταξινομήσεις (Κλάση 1 → 4)
- Δεύτερο μεγαλύτερο: 54 εσφαλμένες ταξινομήσεις (Κλάση 4 → 1)
- Σύνολο 147 σφαλμάτων μεταξύ αυτών των δύο κλάσεων

Πιθανά αίτια:

- Επικαλυπτόμενες κατανομές χαρακτηριστικών στον χώρο PCA
- Παρόμοια μοτίβα στον αρχικό χώρο χαρακτηριστικών
- Μπορεί να αντιπροσωπεύει σταδιακή μετάβαση μεταξύ κλάσεων

ΠΡΟΒΛΕΨΕΙΣ ΣΥΝΟΛΟΥ ΔΟΚΙΜΗΣ

Κατανομή (6.955 δείγματα):

- Κλάση 1: 1.403 (20.2%)
- Κλάση 2: 1.199 (17.2%)
- Κλάση 3: 1.464 (21.0%)
- Κλάση 4: 1.298 (18.7%)
- Κλάση 5: 1.591 (22.9%)

Ισορροπημένες προβλέψεις ταιριάζουν περίπου με την κατανομή εκπαίδευσης

ΣΥΓΚΡΙΣΗ ΙΣΟΡΡΟΠΙΑΣ ΠΡΟΒΛΕΨΕΩΝ

Εκπαίδευση vs Προβλέψεις Δοκιμής:

Κλάση	Εκπαίδευση	Προβλέψεις	Διαφορά
1	20.2%	20.2%	0.0%
2	19.7%	17.2%	-2.5%
3	20.1%	21.0%	+0.9%
4	19.6%	18.7%	-0.9%
5	20.4%	22.9%	+2.5%

Καλή γενίκευση - Χωρίς ακραίες μεταβολές στην κατανομή

ΠΕΡΙΛΗΨΗ ΤΕΛΙΚΟΥ ΜΟΝΤΕΛΟΥ

Επιλεγμένο Μοντέλο: SVM με Πυρήνα RBF

- Κανονικοποίηση: C = 1.0
- Είσοδος: 190 συνιστώσες PCA
- Έξοδος: 5 κλάσεις

Απόδοση:

- Ακρίβεια CV: 84.22%
- Ακρίβεια Επικύρωσης: 86.16%
- Προβλέψεις δοκιμής: 6.955 δείγματα

ΔΥΝΑΤΑ ΣΗΜΕΙΑ ΤΗΣ ΠΡΟΣΕΓΓΙΣΗΣ

Τι Λειτούργησε Καλά:

- Το PCA μείωσε τα χαρακτηριστικά χωρίς να θυσιάσει την ακρίβεια
- Το SVM ξεπέρασε σημαντικά τις μεθόδους βασισμένες σε δέντρα
- Η σωστή προεπεξεργασία (κλιμάκωση) κρίσιμη για την απόδοση
- Η συστηματική σύγκριση εντόπισε τον καλύτερο αλγόριθμο
- Πολλαπλές προσεγγίσεις επικύρωσης (CV + holdout)

Ισχυρά Σημεία:

- 86% ακρίβεια στην επικύρωση
- Ισορροπημένη απόδοση σε όλες τις μετρικές
- Λογική υπολογιστική αποδοτικότητα
- Ισχυρή γενίκευση στο σύνολο δοκιμής

ΠΕΡΙΟΡΙΣΜΟΙ ΚΑΙ ΠΡΟΚΛΗΣΕΙΣ

Κύριες Προκλήσεις:

- Σύγχυση Κλάσης 1 και Κλάσης 4 (147 συνολικά σφάλματα).
- Κλάση 1 μόνο 67.7% ακρίβεια.
- Κάποια πληροφορία χάθηκε στο PCA (5% διακύμανση).

Περιορισμοί:

- Χωρίς ετικέτες δοκιμής για αληθινή επικύρωση απόδοσης.
- Ο χρόνος εκπαίδευσης SVM αυξάνεται με το μέγεθος του συνόλου δεδομένων.
- Περιορισμένη ερμηνευσιμότητα (μοντέλο μαύρου κουτιού).

ΣΥΜΠΕΡΑΣΜΑΤΑ

Περίληψη:

- Επιτυχής ανάπτυξη ταξινομητή 5 κλάσεων (86.16% ακρίβεια επικύρωσης).
- SVM με πυρήνα RBF καλύτερη απόδοση μεταξύ 5 αλγορίθμων.

Βασικές Παρατηρήσεις:

- Η προεπεξεργασία (κλιμάκωση + PCA) κρίσιμη για την απόδοση.
- Οι Κλάσεις 1 & 4 εγγενώς δύσκολες στον διαχωρισμό.
- Οι ισορροπημένες προβλέψεις υποδηλώνουν καλή γενίκευση.

ΕΥΧΑΡΙΣΤΟΥΜΕ ΠΟΛΎ!